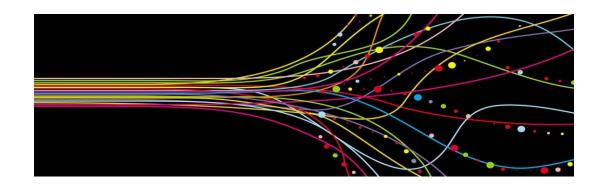
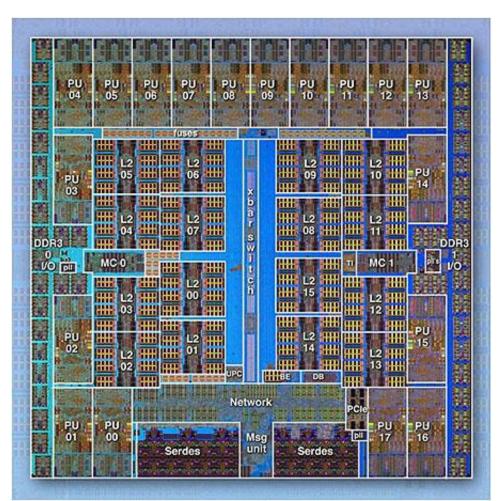
Programarea multi-core și multi-threading -Exemplificare în Java-



De ce multi-core?



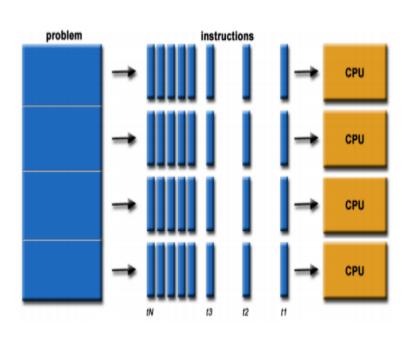
- aplicații cât mai rapide și eficiente;
- viteze mari de calcul și scalabilitate (trebuie să funcționeze pe un număr variabil de procesoare);
- imbunătățiri considerabile în ceea ce privește puterea de procesare și viteza de execuție a aplicațiilor software;
- existența unor aplicații mult mai complexe decât cele existente;
- noi moduri de cercetare și explorare științifice;
- in 2001 IBM introduce primul procesor multi-core cu două nuclee de procesare;



Arhitectură multi-core cu 18 core-uri



1. Procesarea paralelă



- utilizarea simultană a mai multor resurse de calcul pentru a rezolva o problemă computațională;
- o problemă este împărțită în mai multe părți;
- fiecare parte este divizată într-o serie de instrucțiuni;
- instrucțiunile se execută simultan pe diferite procesoare;
- se utilizează un mecanism general de control;

• Resursele de calcul pot fi:

- Un calculator cu mai multe procesoare/nuclee
- Un număr de calculatoare conectate într-o rețea
- **Procesarea paralelă** include tehnici si tehnologii care fac posibil calculul în paralel: hardware, rețele, sisteme de operare, biblioteci, limbaje, compilatoare, algoritmi, etc.

• Avantajele procesării paralele:

- Timp de calcul mai rapid
- Rezolvarea unor probleme mai mari si mai complexe
- Folosirea efectivă a resurselor de calcul
- Costuri reduse
- Reducerea constrângerilor asociate memoriei
- Limitările mașinilor seriale
- Limitele și costurile procesării paralele

2. Limitari ale programarii paralele

Legea lui Amdahl definește limitările fundamentale ale programării paralele, oferind o evaluare a performanțelor mașinilor de calcul, în special în cazul utilizării de procesoare multiple – sau cu mai multe core-uri. Se poate defini un Factor de Accelerare, FA, prin care se poate stabili de câte ori mașina îmbunătățită va rula mai repede pornind de la timpii de executie vechi si nou.

$$FA = rac{T_E V}{T_E N} = rac{timpexecutievechi}{timpexecutienou}$$

Programare paralelă

- Worker = Thread = Fir de execuție.
- O bucată de cod care se execută asincron față de restul programului.
- Multi threading = mai multe threaduri executate asincron în cadrul aceleiași aplicații.

Paralelism in computer science

- Problemă: Doresc să adun toate numerele de la 0 la 100, cum pot face acest lucru cel mai eficient?
- A) Adun numerele unul câte unul pană ajung la 100.
- B) Împart cele 100 de numere în 2 categorii 0 -> 49, 50 -> 100, le adun în paralel iar la final adun cele 2 sume.
- C) Împart numerele în 4 categorii si procedez ca la punctul B.

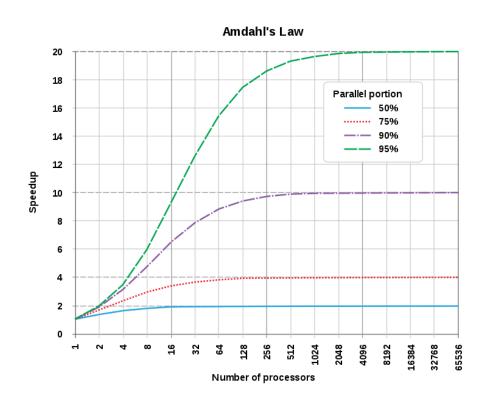
Parallelism in computer science

- Timpul necesar adunării numerelor 0 -> 100 cu 1 worker = 10s.
- Timpul necesar adunării numerelor cu 1 worker de la 0->50 este 5s, iar de la 0->100 cu 2 worker este ~5s.
- Timpul necesar adunării numerelor cu 1 worker de la 0->25 este de 2.5s iar de la 0->100 cu 4 worker este de ~ 2.5s.

Parallelism in computer science

- Dacă numărul de workeri => **∞** atunci timpul de execuție => 0 ???
- Legea lui Amdahl: $S = \frac{1}{(1-p) + \frac{p}{N}}$
- S viteza teoretica
- p portiunea paralelizabila
- N numar de core-uri

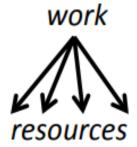
Paralelism in computer science

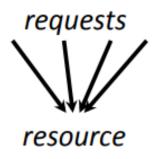


3. Paralelism vs. Concurență

Paralelism:

- mai multe resurse de calcul pentru a rezolva o problemă mai rapid;
- mai multe niveluri de paralelism: *procese, thread-uri, rutine, instructiuni, etc*;
- resurse hardware: *procesoare*, *nuclee* (*core-uri*), *memorii*, *rețele*, *etc*;





Concurență:

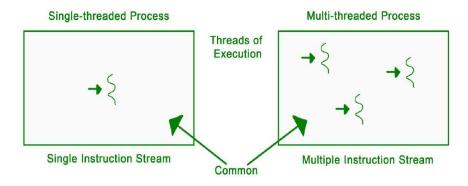
gestiunea corectă și eficientă a accesului la resurse comune;

concurența este fundamentală în computer science: sisteme de operare, baze de date, networking, etc;

- **Multi-tasking** = capacitatea unui sistem de calcul de a executa mai multe programe în același timp (1, ..., n) procesoare);
- Execuție paralelă:
 - task-urile se execută efectiv în același timp;
 - este necesară existența de multiple resurse de calcul;
- task-urile se consideră a fi *pur paralele* dacă se execută în același timp (execuție paralelă);
 - task-urile sunt dependente;

4. Thread-uri (Fire de execuție)

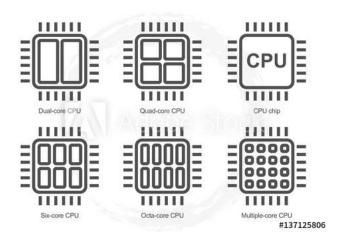
- **Thread** = secvență de cod dintr-o aplicație care se rulează separat față de firul de execuție principal al aplicației;
- Un proces este format de obicei din zeci sau sute de thread-uri;
- **Single-threading** = procesarea unei activitati la un moment dat;
- **Multi-threading** (extensie a multi-tasking-ului) = capacitatea unui program de a executa mai multe secvențe de cod dintr-un program în același timp;



Single Thread and Multi Thread Process

5. Arhitecturi multi-core

- puterea de procesare a calculatoarelor cunoscute a crescut exponențial;
- primele procesoare: 4 biţi lăţimea magistralelor;
 - module de operare;
 - frecvența de tact era de ordinul kiloherților;
- procesoarele din zilele noastre: mult mai puternice;
 - pot opera pe date de 128 de biţi;
 - au frecvențe de tact de până la 5 GHz;
 - au mai multe core-uri;



6. Tehnici de paralelizare

- Arhitecturi pipeline se folosesc de un singur core astfel sunt paralelizate instrucțiuni punându-se într-o coadă și executându-se fiecare într-o manieră secvențială;
- Arhitecturi multi-core sau multi-threaded folosesc mai multe nuclee deținute de procesor, fiind executate instrucțiuni în paralel în același timp;
- Arhitecturi de hyper-threading (firma Intel) prin care programatic este vizualizata o clonă a fiecărui nucleu din cadrul procesorului, fizic ele nu există dar din punct de vedere programatic și logic ele servesc drept nuclee adevărate pentru a fi paralelizate;
- → Arhitecturi distribuite mai multe procesoare, nu doar nuclee de procesoare, mai multe sisteme de calcul independente interconectate în scopul execuției unor task-uri comune, în variantă paralelă;
- Arii de micro-nuclee paralele tehnica mai este numită si CUDA de către cei de la Nvidia, sau stream processors de către cei de la AMD, și este utilizată la plăcile grafice;

7. Multi-threading (programarea concurentă) în Java

- **Java** = limbaj de programare multi-threading;
- Există cel puțin un fir de execuție (firul metodei *main()*);
- Firele de execuție partajează resursele proceselor (memorie, fișiere, etc.);
 - Avantaj: procesare paralelă, viteză mărită de calcul;
 - Dezavantaj: probleme de acces simultan la aceleași resurse;

• Suport initial pentru multi-threading în Java:

- interfața java.lang.Runnable;
- clasa *java.lang.Thread*;
- clasa java.lang.ThreadGroup;
- Crearea unui fir de execuţie;
- Clasa Thread:
 - se creează o clasă derivată din clasa java.lang.Thread;
 - se redefineste metoda *public void run()* moștenită din clasa Thread în clasa derivată;
 - se instanțiază clasa definită;
 - se pornește thread-ul instanțiat prin apelul metodei *start()*;

```
public class ThreadExample1 extends Thread {

public void run() {
    System.out.println("My name is: " + getName());
}

public static void main(String[] args) {
    ThreadExample1 t1 = new ThreadExample1();
    t1.start();

System.out.println("My name is: " + Thread.currentThread().getName());
}

System.out.println("My name is: " + Thread.currentThread().getName());
}
```

```
Thread-0 - numele thread-ului creat;
```

1 My name is: Thread-0 2 My name is: main

main - numele thread-ului principal care pornește în program;

Interfața Runnable

```
public class ThreadExample2 implements Runnable {
 2
         public void run() {
             System.out.println("My name is: " + Thread.currentThread().getName());
 4
 5
 6
         public static void main(String[] args) {
             Runnable task = new ThreadExample2();
 8
             Thread t2 = new Thread(task);
 9
             t2.start();
10
11
12
             System.out.println("My name is: " + Thread.currentThread().getName());
13
14
15
```

Controlul firelor de execuție:



Pornirea și oprirea firului de execuție:

public void start() – executarea corpului metodei run();
 public void stop() – metoda depreciată; este de preferat ca metoda
 run() să își încheie execuția;

Punerea pe pauză pentru intervale de timp determinate:



public void sleep(long ms);
public void sleep(long ms, int ns);

```
public class NumberPrint implements Runnable {
 2
 3
         public void run() {
 4
 5
             for (int i = 1; i <= 5; i++) {
 6
                 System.out.println(i);
 8
 9
                 try {
10
                     Thread.sleep(2000);
11
12
                 } catch (InterruptedException ex) {
13
                     System.out.println("I'm interrupted");
14
15
16
17
18
         public static void main(String[] args) {
19
             Runnable task = new NumberPrint();
20
             Thread thread = new Thread(task);
21
             thread.start();
22
23
24
25
```

```
public class ThreadInterruptExample implements Runnable {
 2
 3
         public void run() {
             for (int i = 1; i <= 10; i++) {
 4
                  System.out.println("This is message #" + i);
 5
 6
 7
                  try {
                      Thread.sleep(2000);
 8
 9
                      continue;
                  } catch (InterruptedException ex) {
10
                      System.out.println("I'm resumed");
11
12
13
14
15
16
         public static void main(String[] args) {
17
             Thread t1 = new Thread(new ThreadInterruptExample());
18
             t1.start();
19
20
             try {
                  Thread.sleep(5000);
21
22
                  t1.interrupt();
23
             } catch (InterruptedException ex) {
24
25
                  // do nothing
26
27
28
29
```

public void interrupt(); întreruperea unui thread poate fi folosită pentru a opri sau a relua execuția acelui thread de către alt thread;

```
public class ThreadJoinExample implements Runnable {
1
2
3
         public void run() {
 4
             for (int i = 1; i <= 10; i++) {
 5
                 System.out.println("This is message #" + i);
 6
                 try {
                      Thread.sleep(2000);
 8
9
                 } catch (InterruptedException ex) {
                     System.out.println("I'm about to stop");
10
11
                      return;
12
13
14
15
         public static void main(String[] args) {
16
             Thread t1 = new Thread(new ThreadJoinExample());
17
18
             t1.start();
19
             try {
20
21
                 t1.join();
22
23
             } catch (InterruptedException ex) {
24
25
                 // do nothing
26
27
             System.out.println("I'm " + Thread.currentThread().getName());
28
29
30
```

```
This is message #1
This is message #2
This is message #3
This is message #4
This is message #5
This is message #6
This is message #7
This is message #8
This is message #8
This is message #9
This is message #10
I'm main
```

- public void join();
- public void join(long ms, int ns);
- este folositor în cazul în care thread-ul curent trebuie să aștepte alte thread-uri săși termine execuția;

Programare paralelă-Thread

```
Main.java × © MyThread.java × © MyThreadImpl.java ×

public class MyThread extends Thread {
    private String name;

MyThread(String name) {
    this.name = name;
    }

public void run() {
    for (int i = 0; i < 50; i++) {
        Main.sum += i;
        System.out.println(name + ":" + Main.sum);
    }
}</pre>
```

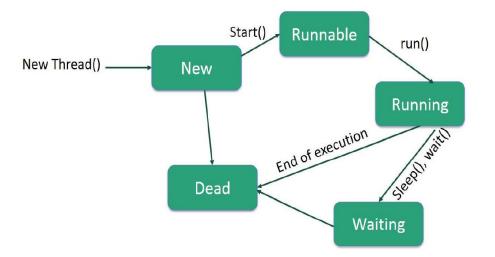
Programare paralelă-Runnable

Programare paralelă-main

Thread2:0
Thread1:0
Thread2:1
Thread1:2
Thread2:4
Thread1:6
Thread2:9
Thread1:12
Thread2:16
Thread2:25
Thread1:30

• Stările unui thread:

- *New* thread-ul a fost creat, dar nu s-a pornit;
- *Runnable* thread-ul este inițializat și poate fi pornit sau este deja pornit;
- **Running** thread-ul este în etapa de execuție a unui task (starea spre care aspiră toate firele de execuție);
- *Waiting* thread-ul este suspendat temporar și așteaptă un semnal pentru a reîncepe execuția;
- *Timed Waiting* thread-ul este suspendat temporar de către programator, dar la intervale fixe de timp;
- **Dead** un thread intră în această stare când și-a terminat execuția (acesta nu mai poate fi repornit);



• Grupuri de thread-uri

Clasa java.lang.ThreadGroup

- tratarea unitară a firelor de execuție care sunt membre în grup;
- ThreadGroup este o clasă care grupează anumite thread-uri ca o singură unitate și permite efectuarea unor operații pe un grup ca și un întreg (ansamblu) mai bine decât fiecare thread separat;
 - numele grupului trebuie specificat în momentul creării sale;

• Prioritațile thread-urilor

- fracțiunea de timp alocat rulării din timpul total de rulare;
- fiecare thread are o valoare a priorității care sugerează programatorului cât de mult trebuie să aibă grijă în cazul în care mai multe thread-uri rulează;
- atunci când se creează un thread nou, acesta are aceeași prioritate cu cel din metoda *main()*;
 - prioritatea poate fi setată prin apelarea *Thread.setPriority(int priorityLevel)*;
 - există 3 niveluri de prioritate:

 $Thread.MIN_PRIORITY = 1$

Thread.NORM_PRIORITY = 5 // valoare implicită

 $Thread.MAX_PRIORITY = 10$

-se poate seta totuși orice valoare de la 1 la 10;

Thread-uri Daemon

- Java definește două tipuri de thread-uri: thread-uri normale (user thread-uri) și thread-uri Daemon (in serviciul altor thread-uri);
- implicit atunci când se creează un thread nou acesta este user thread;
- Java Virtual Machine (JVM) nu isi termina execuția dacă există încă user thread-uri care rulează, dar se termină dacă există doar thread-uri Daemon;
- un thread Daemon poate fi creat prin apelul metodei *Thread.setDaemon(true)*, iar starea acestuia poate fi verificată folosind metoda *isDaemon()*;

Sincronizarea thread-urilor

- Posibilitatea accesării simultane de către mai multe fire de execuție a unor resurse (variabile, metode);
- Thread-urile au o memorie comună pe care o împart, astfel intervine conceptul de resource *lock* (*mutex mutual excluson*) pentru accesul secvențial la resurse;
- Într-o aplicație multi-threading există posibilitatea ca mai multe thread-uri să acceseze simultan aceleași date, fapt care conduce la apariția unei stări inconsistente a datelor (corupția datelor);

- Există urmatoarele situații:
- **deadlock** -> situația în care două sau mai multe fire de execuție se așteaptă reciproc pe termen nedeterminat;
- **starvation ->** situația în care un fir de execuție așteaptă (fară rezultat) accesul la resurse partajate;
 - -> poate apărea din urmatoarele motive:



-Thread-urile sun blocate la infinit deoarece unui thread îi este necesar prea mult timp pentru a executa o secvență de cod sincronizată (ex: operații de intrari/ieșiri)



-Un thread nu primește timp de execuție de la procesor deoarece are o prioritate prea mică în comparație cu alte thread-uri;

- *livelock* -> situația în care un fir de execuție reacționează la rularea altui fir de execuție (thread-urile nu progresează datorită faptului că își cedează reciproc execuția);
- -> spre deosebire de starea *deadlock*, în această situație tread-urile nu se vor bloca;
- -> ex: 2 persoane care doresc să treacă simultan prin același coridor;

Monitor (Semafor)

Monitor = un obiect care asigură că o variabilă partajată poate fi accesată întrun moment dat de cel mult un fir de execuție (*semafor*);

- -> în cazul în care resursa este accesată, se pune un *lock* pe aceasta, astfel încât să împiedice accesul altor fire de execuție la ea;
- -> în momentul în care resursa este eliberată, "*lock-ul*" va fi eliminat pentru a permite accesul altor fire de execuție;

Monitorul este numit și *semafor*, iar programatorii consideră că firul păstrează monitorul pentru acel moment.

Un thread va utiliza un monitor pentru o perioadă limitată de timp.

Dacă monitorul nu este disponibil, firul va fi suspendat într-o stare de așteptare.

Monitorul este o construcție de *sincronizare* care permite thread-urilor să aibă atât excludere reciprocă – *mutual exclusion* (folosind *lock-uri*), cât și *co-operare* (comunicare inter-thread sau cooperare), adică capacitatea de a face thread-urile să aștepte ca anumite condiții să fie adevărate (folosind un mecanism *wait/notify*).

Thread Pool

- -> utilizat pentru a porni o mulțime de thread-uri de durată scurtă pentru a utiliza eficient resursele și de a crește astfel perfomanța;
- -> păstrează un număr de thread-uri inactive pregătite de executarea task-urilor necesare (după ce un thread termină de executat un task, aceasta rămâne inactiv în pool și așteaptă să fie selectat pentru a executa noi task-uri);
- -> se poate defini un numar limitat de thread-uri în *pool*, util pentru a preveni supraîncărcarea;

-Tipuri de thread pool-uri:

- *Catched thread pool: păstrează un număr de thread-uri active și creează altele noi dacă este nevoie;
- **Fixed thread pool*: limitează numărul maxim de thread-uri concurente. Task-urile adiționale sunt plasate într-o coadă de așteptare;
- *Single-threaded pool: păstrează doar un thread care execută un task la un moment dat;
- *Fork/join pool: un thread pool special care utilizează framework-ul Fork/Join pentru a se folosi de avantajele procesorului care împarte o sarcină mai complexă în mai multe părți mai mici într-un mod recursiv;

• Executori – introdusi in package-ul concurrent cu Java SE5

Executor = obiect care este responsabil pentru gestionarea thread-urilor și de executarea sarcinilor *Runnable*; A fost extins odata cu evolutia Java.

```
1 Thread t = new Thread(new RunnableTask());
2 t.start();
```

Se poate înlocui cu:

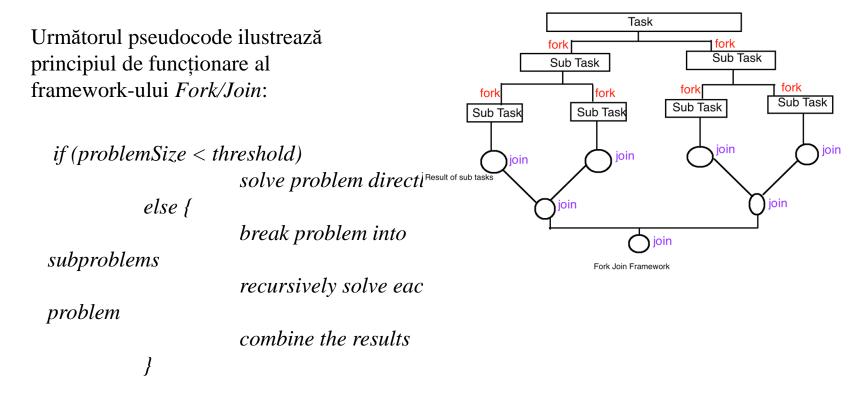
```
Executor executor = anExecutorImplementation;
executor.execute(new RunnableTask1());
executor.execute(new RunnableTask2());
```

• Există trei interfețe de bază pentru executori:

- *Executor: interfață simplă care permite rularea de procese asociate firelor de execuție;
 - are definită metoda void execute (Runnable command);
- *ExecutorService (derivată din Executor): adaugă facilități de gestionare a ciclului de viață a proceselor și a executorilor;
- adaugă metoda *Future*<?> *submit*(*Runnable task*) care permite utilizarea obiectului *Future* returnat;
- *ScheduledExecutorService (derivata din Executor Service): permite în plus executarea viitoare sau periodică a proceselor;
- adaugă metoda *<V> ScheduledFuture<V> schedule(Callable<V> callable, long delay, TimeUnit unit)* care permite rularea sarcinilor la un moment de timp viitor;

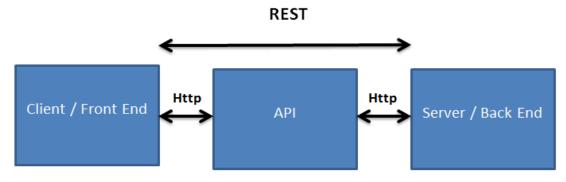
• Framework-ul Fork/Join

Framework-ul *Fork/Join* = set de API-uri care permite programatorului să se folosească de avantajele procesării paralele prin intermediul procesoarelor multi-core;



- Framework-ul *Fork/Join* utilizat în: procesarea imaginilor, procesarea video, cantități mari de date, etc;
- Pentru a spori performanțele acestui framework, *fork/join* are propriul thread pool care gestionează thread-urile lucrătoare, *forkJoinPool*. Acest pool creează un thread pentru fiecare sub-task supus unei execuții, pentru a se folosi la maxim de procesor, printr-un algoritm de tip *work-stealing*;

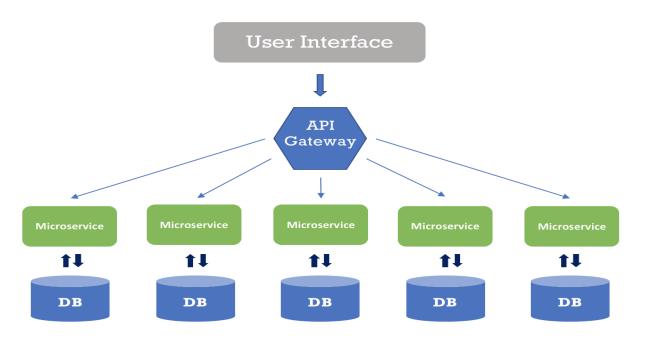
Multithreading în aplicații Web

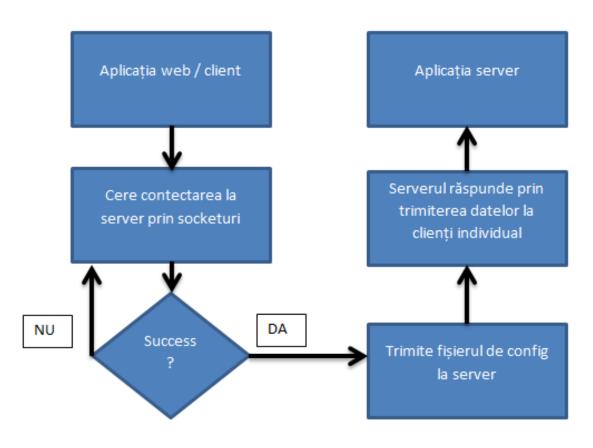


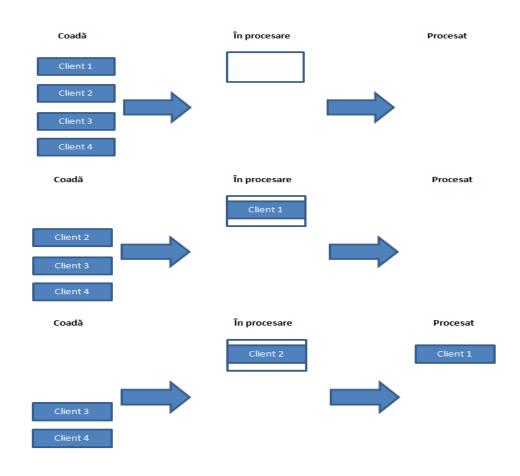
- **HTTP** = Hypertext Transfer Protocol, protocol de comunicare în internet.
- **API** = Application Programming Interface, este o interfață / protocol / "contract" de comunicare între client și server.
- **REST** = Representational State Transfer, un set de constrângeri expuse pentru un contract comun de comunicare (folosește HTTP)

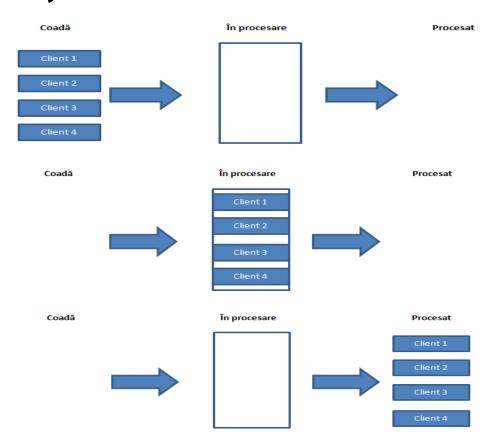
Multithreading în aplicații web · Microserviciu = tehnică de proiectare orientată spre

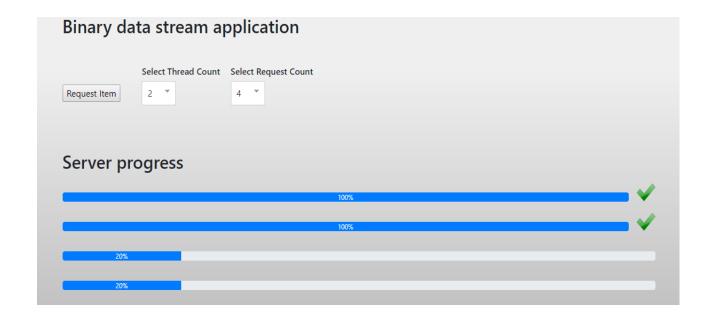
• **Microserviciu** = tehnică de proiectare orientată spre servicii simple care comunică între ele folosind un protocol comun (REST).









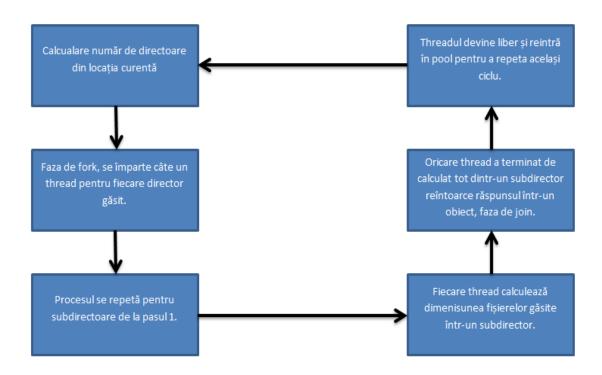


- Rezultate:
- 1 core 4 clienți **2**20 sec
- 2 core 4 clienți **2**10 sec
- 3 core 4 clienți **2**10 sec
- 4 core 4 clienți **2**5 sec

Aplicația Fork / Join Recusiv

- Microserviciu în Java.
- Împărțirea lucrului (task) între mai multe threaduri (faza de *fork*).
- Executarea procesării de către fiecare thread individul (execuția taskului).
- Adunarea rezultatelor de la fiecare thread (faza de *join*).

Aplicația Fork / Join Recusiv



Aplicația Fork / Join Recusiv

Conținut de 4 GB 120% mai rapid

```
: Size of 'D://BACKUP': 3993188896 bytes (in 4.409 s)

| Size of 'D://BACKUP': 3993188896 bytes (in 3.765 s)

: Size of 'D://BACKUP': 3993188896 bytes (in 3.448 s)

: Size of 'D://BACKUP': 3993188896 bytes (in 3.112 s)

: Size of 'D://BACKUP': 3993188896 bytes (in 3.358 s)

: Average run time is 3.62 s

: Size of 'D://BACKUP': 3993188896 bytes (in 1.834 s)

: Size of 'D://BACKUP': 3993188896 bytes (in 1.685 s)

: Size of 'D://BACKUP': 3993188896 bytes (in 1.495 s)

: Size of 'D://BACKUP': 3993188896 bytes (in 1.606 s)

: Size of 'D://BACKUP': 3993188896 bytes (in 1.584 s)

: Average run time is 1.64 s

: Overall performance difference, 1 thread took 3.62 s, recursive multicore took 1.64 s, 120.53% performance difference
```

Continut de 337 GB **@**350% mai rapid

```
: Size of 'F://': 337159798151 bytes (in 96.633 s)

'Size of 'F://': 337159798151 bytes (in 8.051 s)

: Size of 'F://': 337159798151 bytes (in 8.038 s)

: Size of 'F://': 337159798151 bytes (in 8.038 s)

: Size of 'F://': 337159798151 bytes (in 7.975 s)

: Average run time is 25.81 s

: Size of 'F://': 337159798151 bytes (in 6.021 s)

: Size of 'F://': 337159798151 bytes (in 5.949 s)

: Size of 'F://': 337159798151 bytes (in 5.184 s)

: Size of 'F://': 337159798151 bytes (in 5.22 s)

: Size of 'F://': 337159798151 bytes (in 6.296 s)

: Average run time is 5.73 s

: Overall performance difference, 1 thread took 25.81 s, recursive multicore took 5.73 s, 350.10% performance difference
```

Aplicația GPU render vs CPU render

- Procesoarele grafice au sute de "mini" core-uri(CUDA, stream processor).
- Calcule simple dar foarte multe (GPU) mai complexe dar mai putine (CPU).
- GPU este folosit în randare video 2D, 3D, realitate virtuală și augmentată dar și în criptografie.
- Un proces foarte des întâlnit pentru măsurarea performanțelor este calcularea de numere prime (100k).

Aplicația GPU render vs CPU render

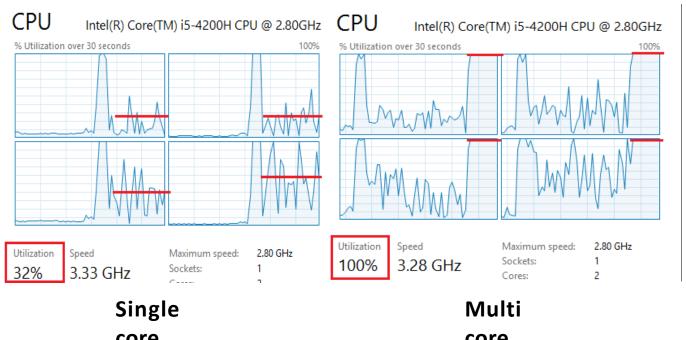
```
Device 9847360
 vendor = NVIDIA Corporation
 type:GPU
 maxComputeUnits=5
 maxWorkItemDimensions=3
 maxWorkItemSizes={1024, 1024, 64}
 maxWorkWorkGroupSize=1024
 globalMemSize=2147483648
 localMemSize=49152
Device 462413760
 vendor = Intel(R) Corporation
 type:GPU
 maxComputeUnits=20
 maxWorkItemDimensions=3
 maxWorkItemSizes={512, 512, 512}
 maxWorkWorkGroupSize=512
 globalMemSize=1708759450
 localMemSize=65536
Device 10131040
 vendor = Intel(R) Corporation
 type:CPU
 maxComputeUnits=4
 maxWorkItemDimensions=3
 maxWorkItemSizes={8192, 8192, 8192}
 maxWorkWorkGroupSize=8192
 globalMemSize=8467283968
 localMemSize=32768
```

```
CPU single core
time taken: 21428 ms
CPU multi core
time taken: 7190 ms
GPU multi core
time taken: 1346 ms
Relative performance difference 1491.98%
```

Diferența de performanță între CPU single core și GPU este de **1491.98%** iar între CPU multi core și GPU este de **530%**.

Biblioteca folosită pentru programare GPU este openCL (Computing Library)

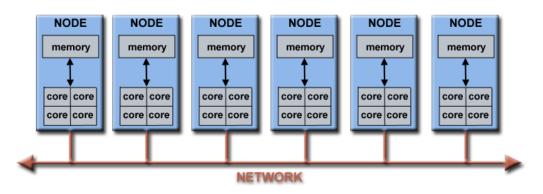
Aplicația GPU render vs CPU render



core

core

8. Concluzii



- -Cele mai utilizate limbaje de programare sunt cele din domeniul server side, capabile să ruleze aplicații pe mai multe core-uri;
- -Există numeroase framework-uri în Java dedicate programării paralele și multi-core;
- -Sistemele multi-processor/core prezintă și disponibilitate crescută, pentru că se pot defecta unele procesoare/core-uri și sistemul trebuie să funcționeze cu procesoarele/core-urile rămase;