

Lab 11. Recunoașterea obiectelor din imagini digitale monobiect, fără extragerea și selecția trăsăturilor, folosind clasificatoare masini cu vectori suport (SVM) binare

Clasificatorul SVM binar

Notatii matematice:


- Spatiul trasaturilor: $\mathbb{R}^F \Rightarrow F$ = dimensiunea spatiului trasaturilor
 - Date de antrenare: $X_{\text{trn}} = \{\mathbf{x}_{t,1}, \mathbf{x}_{t,2}, \dots, \mathbf{x}_{t,N_{\text{trn}}}\}$; etichetele datelor de antrenare: $Y_{\text{trn}} = \{y_{t,1}, y_{t,2}, \dots, y_{t,N_{\text{trn}}}\}$, $y_{t,i} = +1$ sau -1 .
 - SVM = clasificator binar capabil sa separe datele in 2 clase:
 - a) clasa exemplelor pozitive**, etichetate cu $+1$, pentru o problema de clasificare data (ex.: clasa imaginilor faciale)
 - b) clasa exemplelor negative**, etichetate cu -1 , pentru problema de clasificare data = orice alt tip de date decat cele pozitive (ex.: orice alta imagine decat o imagine faciala)
- \Rightarrow SVM clasifica datele in “exemple pozitive” si “exemple negative” \Leftrightarrow intr-o clasa C si o clasa $non-C$.

Principiul de separare a datelor in cele 2 clase in clasificatorul SVM binar:

*separarea datelor de catre un **hiperplan separator optimal** \mathcal{H} , care separa exemplele din cele doua clase fara eroare si cu **margine maxima** = cu distanta maxima de la cel mai apropiat exemplu pozitiv la \mathcal{H} si de la cel mai apropiat exemplu negativ la \mathcal{H} .*


Principiul recunoasterii obiectelor cu SVM binare

1. Descrierea obiectelor intr-un spatiu al trasaturilor:



2. Generarea fisierului de antrenare al SVM:

Exemple pozitive




Exemple negative



```
+1 1:0.3686274509803921 2:0.3764705882352941 3:0.3686274509803921 4:0.139:0.2078431372549019 140:0.1686274509803921 141:0.1843137254901960
272:0.5019607843137254 273:0.4941176470588235 274:0.5019607843137254
405:0.5019607843137254 406:0.4980392156862745 407:0.4941176470588235
+1 1:0.3686274509803921 2:0.3686274509803921 3:0.3647058823529411 4:0.139:0.1960784313725490
140:0.1568627450980392 141:0.1607843137254902
272:0.5098039215686274 273:0.5019607843137254 274:0.4980392156862745
405:0.5098039215686274 406:0.5058823529411764 407:0.4980392156862745
-1 1:0.3568627450980392 2:0.3607843137254902 3:0.3725490196078431 4:0.139:0.2039215686274509
140:0.1803921568627450 141:0.2313725490196078
272:0.4980392156862745 273:0.5019607843137254 274:0.4980392156862745
405:0.5058823529411764 406:0.5058823529411764 407:0.5098039215686274
```

3. Antrenare SVM
 \Rightarrow
hiperplanul separator optim:



4. Recunoasterea obiectelor necunoscute:




$f(\mathbf{x}) < 0 \Rightarrow$ **clasa 2**

$$f(\mathbf{x}) = \sum_{i=1}^L \alpha_i y_i \cdot \mathbf{K}(\mathbf{x}, \mathbf{x}_i) + b$$


Etapa de antrenare a SVM

În funcție de gradul de separabilitate al datelor de clasificat în spațiul trăsăturilor lor, putem utiliza :

•**SVM liniare**, pt. date liniar separabile => ecuația hiperplanului separator optimal se deduce în \mathbb{R}^F .



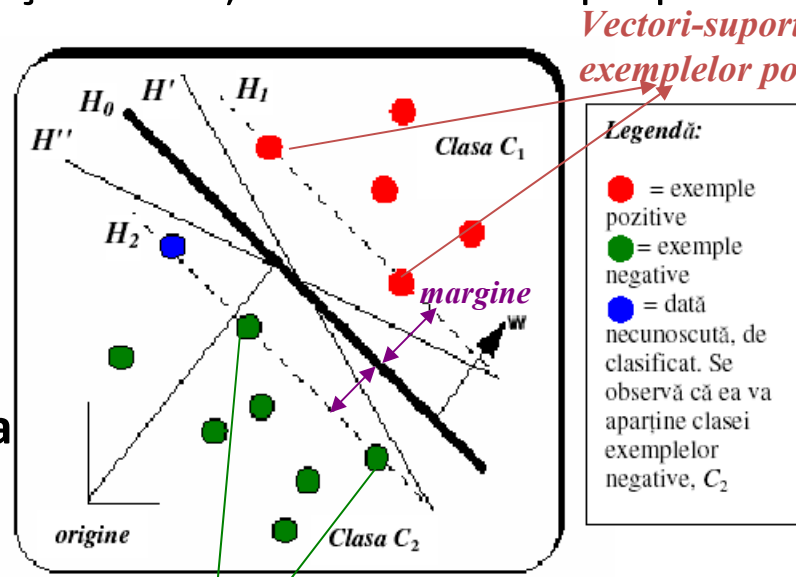
•**SVM neliniare**, pt. date nelinear separabile liniar în \mathbb{R}^F => nu putem deduce un hiperplan care să separe datele în \mathbb{R}^F => SVM proiectează datele într-un spațiu de dimensiune mai mare, \mathbb{R}^M , $M > F$, în care datele devin liniar separabile. Hiperplanul separator este dedus în spațiul înalt dimensional \mathbb{R}^M .



Cazul SVM liniar (1)

- Procesul de învățare al SVM = găsirea parametrilor unui hiperplan \mathcal{H}_0 în \mathbb{R}^F care:
 - să separe perfect exemplele pozitive și exemplele negative din X_{trn} în \mathbb{R}^F
 - să **maximizeze marginea** \Leftrightarrow să maximizeze distanța celui mai apropiat exemplu pozitiv și distanța celui mai apropiat exemplu negativ la hiperplanul \mathcal{H}_0 .

\mathcal{H}_0 = hiperplanul
separator optimal
= “media”
hiperplanelor limita
definite de vectorii
suport: $\mathcal{H}_1, \mathcal{H}_2$




Principiul separării datelor în procesul de clasificare binară în mașina cu vectori suport

Vectori-suport din clasa exemplelor negative

Cazul SVM liniar (2)

- Este posibilă definirea mai multor hiperplane care să separe perfect datele din mulțimea de antrenare : $\mathcal{H}_0, \mathcal{H}'_0, \mathcal{H}''_0$.
- Doar hiperplanul \mathcal{H}_0 dă **distanța maximă** de la cel mai apropiat exemplu pozitiv și cel mai apropiat exemplu negativ la hiperplan $\Rightarrow \mathcal{H}_0 =$ **hiperplan separator optimal**
- Hiperplanul separator optimal este paralel cu hiperplanele-limită \mathcal{H}_1 și \mathcal{H}_2 , fiind situat la mijlocul distanței dintre ele.



Cazul SVM liniar (3)

- $\mathcal{H}_1, \mathcal{H}_2$ = hiperplanele cu proprietatea că, nici una din datele de antrenare nu cade între ele, dar există date de antrenare și pe \mathcal{H}_1 , și pe \mathcal{H}_2 .
- Datele de antrenare situate pe \mathcal{H}_1 și \mathcal{H}_2 = **vectorii suport ai SVM**.
- Vectorii suport = singurele date necesare pentru definirea SVM, deoarece permit definirea univocă a \mathcal{H}_0 :
 - Vectorii suport formați din exemple de antrenare pozitive definesc complet ecuația hiperplanului \mathcal{H}_1
 - Vectorii suport formați din exemple de antrenare pozitive definesc complet ecuația hiperplanului \mathcal{H}_2
 - Odată definite \mathcal{H}_1 și \mathcal{H}_2 prin ecuațiile lor matematice \Rightarrow ecuația matematică a hiperplanului separator optimal \mathcal{H}_0 se poate defini prin "media" ecuațiilor hiperplanelor \mathcal{H}_1 și \mathcal{H}_2 , respectiv, prin ecuația acelui hiperplan care este paralel și cu \mathcal{H}_1 , și cu \mathcal{H}_2 , și este amplasat exact la mijlocul distanței dintre ele.
- Pentru exemplul din fig. anterioară, avem câte două exemple din fiecare clasă aflate pe hiperplanele-limită \Rightarrow numărul de vectori suport = 4 (2 vectori suport cu eticheta +1; 2 vectori suport cu eticheta -1).

Cazul SVM liniar (4)

- Ecuația matematică a hiperplanului \mathcal{H}_0 în spațiul \mathbb{R}^F al datelor se exprimă ca:

$$H_0 : \mathbf{w} \cdot \mathbf{x} + b = 0,$$

unde \mathbf{w} = vectorul normal la hiperplan; b = termenul liber al hiperplanului.

- Suma distanțelor celui mai apropiat exemplu negativ la hiperplanul \mathcal{H}_0 și a celui mai apropiat exemplu pozitiv la hiperplanul \mathcal{H}_0 este dată de expresia $\frac{2}{\|\mathbf{w}\|}$ și se numește margine. $\|\mathbf{w}\|$ = norma Euclidiană a vectorului \mathbf{w} .
- **Problema antrenării SVM** = deducerea parametrilor \mathbf{w} și b ai hiperplanului separator optimal \mathcal{H}_0 astfel încât marginea să fie maximizată, iar exemplele pozitive și negative să respecte următoarele constrângeri ca nici unul dintre ele să nu "cadă" în interiorul marginii de separare a claselor, adică, să nu fie amplasate între hiperplanele-limită \mathcal{H}_1 și \mathcal{H}_2 :

$$\begin{cases} \mathbf{w}^T \mathbf{x}_i + b \geq 1, & \text{pentru } y_i = +1 \\ \mathbf{w}^T \mathbf{x}_i + b \leq -1, & \text{pentru } y_i = -1 \end{cases}, \quad \forall i = 1, 2, \dots, N_{trn}.$$

Cazul SVM liniar (5)

- Problema de maximizare a marginii cu constrângeri de tip inecuație se poate rezolva cu ajutorul multiplicatorilor Lagrange.
- Datele \mathbf{x}_k din mulțimea de antrenare pentru care, în urma procesului de optimizare, se obțin multiplicatori Lagrange $\alpha_k = 0$ nu vor interveni în expresia matematică a funcției de decizie a clasificatorului mașină cu vectori suport.
- Celelalte date, pentru care obținem multiplicatori Lagrange nenuli, sunt importante în definirea ecuației matematice a hiperplanului \mathcal{H}_0 și deci și a funcției de decizie a clasificatorului. Aceste date de antrenare sunt exact **vectorii suport ai clasificatorului**, adică, datele din mulțimea de antrenare care definesc cele două hiperplane-limită \mathcal{H}_1 și \mathcal{H}_2 . Fie N_s = nr. vectorilor suport, $N_s > 0$ și $N_s \leq N_{trn}$.
- Vectorii suport, etichetele lor, valorile multiplicatorilor lor Lagrange asociați și valoarea termenului liber b al hiperplanului deduse în urma procedurii de optimizare sunt suficienți pentru a defini complet mașina cu vectori suport
- Ecuația hiperplanului separator optimal \mathcal{H}_0 al mașinii cu vectori suport definește de fapt și funcția de decizie a clasificatorului mașină cu vectori suport, în următoarea formă:

$$f(\mathbf{x}) = \sum_{i=1}^{N_s} \alpha_i y_i \mathbf{x}^T \mathbf{x}_i + b, \quad \text{sau} \quad y = f'(\mathbf{x}) = \text{sign}(f(\mathbf{x})).$$

Cazul SVM neliniar (1)

- Dacă ***datele de antrenare nu sunt separabile fără eroare printr-un hiperplan în domeniul lor original*** \Rightarrow SVM proiectează datele din spațiul într-un spațiu Hilbert de dimensiune mai înaltă \mathbb{R}^M , cu $M > F$, folosind pentru proiecție o transformare neliniară Φ , $\Phi : \mathbb{R}^F \rightarrow \mathbb{R}^M$
- În noul spațiu, datele devin mai distanțate și vor fi mai ușor de separat liniar \Rightarrow SVM construiește în faza de antrenare hiperplanul separator optimal în noul spațiu \mathbb{R}^M , dat de ecuația:

$$H_0 : \mathbf{w} \cdot \Phi(\mathbf{x}) + b = 0,$$


ca orice SVM liniar, dar nu în \mathbb{R}^F ci în \mathbb{R}^M .

- Similar SVM liniar, în expresia finală a funcției de decizie $f(\mathbf{x})$, datele intervin prin produsele lor scalare în \mathbb{R}^M : $\Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j)$, $\forall i, j = 1, 2, \dots, N_{trn}$.
- În locul folosirii explicite a acestor produse și transformării neliniare Φ , SVM folosesc funcții-kernel $K : \mathbb{R}^F \times \mathbb{R}^F \rightarrow \mathbb{R}$, care implementează calculul:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j), \quad \forall i, j = 1, 2, \dots, N_{trn}.$$

Cazul SVM nelinier (2)

Ilustrare a procesului de proiectie a datelor intr-un spatiu inalt dimensional si deducere a hiperplanului separator optimal in acest spatiu:



Proiectia hiperplanului separator optimal in \mathbb{R}^F ; functia $f(\mathbf{x})=0$.

Hiperplan separator optimal in \mathbb{R}^M

Cazul SVM neliniar (3)

- Exemple de funcții-kernel în clasificatoarele SVM:
 - Funcția-kernel polinomială, de grad d , d – întreg pozitiv nenul:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \left(m \cdot \mathbf{x}_i^T \mathbf{x}_j + n \right)^d,$$

unde: d = gradul polinomului; valori uzuale: 2,3,5 și 7.

m și n = parametri cu valori reale nenule, care reprezintă coeficienții expresiei polinomiale. Uzual, $m=n=1$.

- 6) Funcția-kernel exponențială (RBF)(=radial basis function):

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp \left\{ - \gamma \left| \mathbf{x}_i - \mathbf{x}_j \right|^2 \right\},$$

unde γ reprezintă parametrul cu valori reale pozitive nenule al funcției Gaussiene.

- În urma procesului de învățare al mașinii cu vectori suport neliniare, se obține funcția de decizie (cu valori reale) a clasificatorului sub forma:

$$f(\mathbf{x}) = \sum_{i=1}^{N_S} \alpha_i y_i K(\mathbf{x}, \mathbf{x}_i) + b,$$

Aplicatie practica

1) Se va descarca biblioteca *Matlab Support Vector Machine Toolbox* dezvoltata de catre Steve Gunn, Univ. of Southampton, de la adresa:

<http://www.isis.ecs.soton.ac.uk/isystems/kernel/svm.zip>

Se va dezarhiva aceasta biblioteca in directorul *Toolbox* din *Matlab*

Se va adauga (comanda Set Path) directorul acestui toolbox, cu subdirectoarele sale, la pornirea Matlab-ului

2) La linia de comanda a Matlab-ului, rulati aplicatia *uiclass*. Incarcati pe rand cele trei fisiere de date corespunzatoare problemei de clasificare a florilor de Iris. Care este diferenta intre cele 3 fisiere? Ce problema de clasificare rezolva fiecare dintre ele?

- 3) Analizati, pentru fiecare din cele 3 seturi de date al problemei de clasificare a florilor de Iris, performanta de clasificare a unui clasificator SVM binar linar si a unor clasificatoare SVM binare neliniare, pentru diferite forme de functii kernel. Comentati performantele de clasificare.
- 4) Rulati aplicatia *ObjClassifSVM_LargeDatabase.m* si notati erorile de clasificare in setul de antrenare si in setul de test pentru problema de clasificare data. Comparati performanta de clasificare cu cea a clasificatorului LDA din lucrarea de laborator precedenta.
- 5) Modificati parametrii SVM astfel incat sa se minimizeze rata de eroare in setul de test (atat pentru cazul folosirii numai a luminantei, cat si a culorii) pentru problema de clasificare data.